#### TensorFlow勉強会 第2回

#### TensorFlowで会話AIを作ってみた



#### 自己紹介



新村拓也(しんむら たくや) 1990年鹿児島生まれ

レコメンド、検索エンジン、画像解析、未来予測 などのデータ周りのことをやっています。

シーエイトラボ株式会社代表取締役

## 会話AI



- ◆ LINEやTwitterなどのチャットロボット に活用されている。
- ◆ ゲームのNPCなどにも活用可能。
- ◆ 会話エンジンを用いた雑談APIなども 存在。
- ◆「うずら」、「もずく」、「りんな」等。
- ◆ 様々な種類のアルゴリズムの会話AI が存在するが、なかなか技術は公開 されていない。



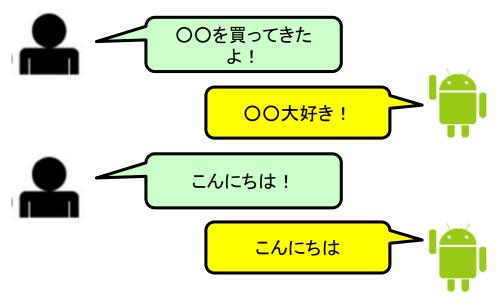
MichroSoft社 女子高生会話AI「りんな」 http://rinna.jp/rinna/

#### 会話AIの種類



#### ◆ 辞書型

辞書に登録されたテンプレに応じて会話を行う。



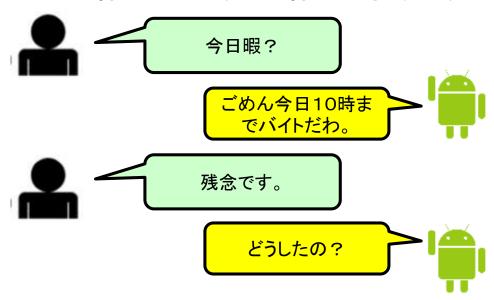
パターンに合致すればおかしな言葉を発することはない 話せるフレーズがパターン辞書の大きさに依存

#### 会話AIの種類



#### ◆ ログ型

学習に用いた会話と似たような会話に応答する。



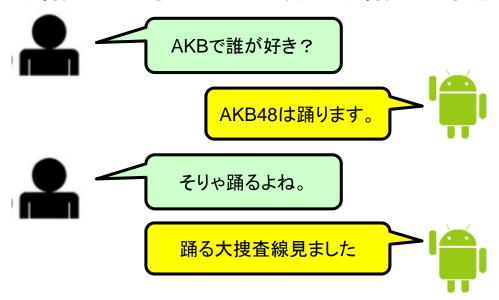
文章自体は非常に人間らしいものになる反応が学習に用いた会話の数に依存する

#### 会話AIの種類



#### ◆ マルコフ型

出現した単語の次に最も出現しそうな単語で文章を生成。

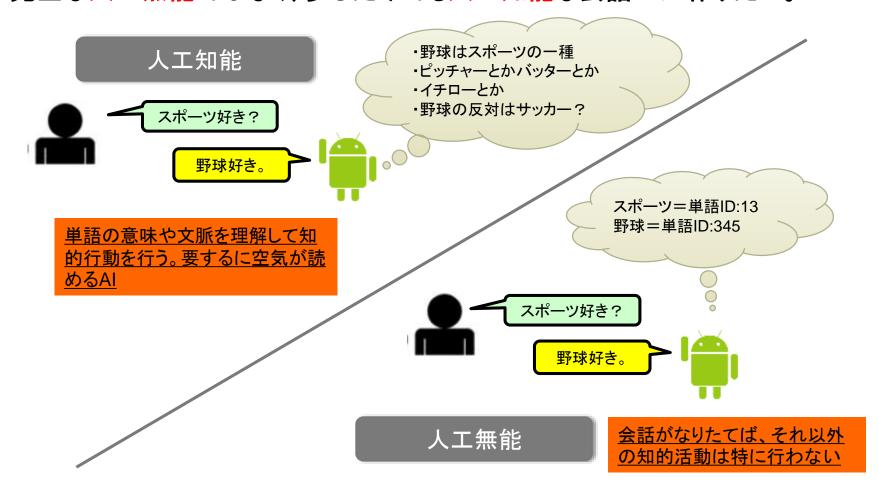


用いることのできるフレーズの数が非常に豊富 確率で文章を生成するため、たまに文脈がとおらないことが

#### モチベーション



完全な人工無能ではなく、少しだけでも人工知能な会話AIが作りたい。



#### 今回作ったAIの特徴



- ◆ 単語レベルの意味獲得は行えるように
  - ◆ ニューラル言語モデルを用いた単語埋め込み
  - ◆ Word2Vecでも用いられている

次に来る単語を予測するモデルを作ることによって、

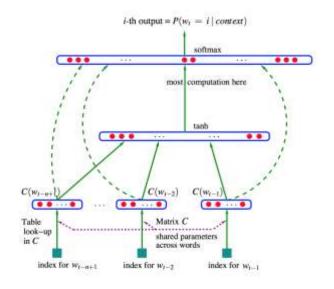
犬=(0.1, 0.5, 2.0, 0.4, 2.4)

猫=(0.1, 0.4, 1.5, 0.3, 2.4)

のように、各単語にベクトルを割り当てる。



王様 – 男性 + 女性 = 女王様 のようなベクトル演算が可能に



Yoshua Bengio, Réjean Ducharme, Pascal Vincent, Christian Jauvin. A Neural Probabilistic Language Model. Journal of Machine Learning Research 3(2003):p1137– 1155

### 今回作ったAIの特徴



- ◆ 会話構築にはSequence to Sequence Modelを採用
  - ◆ TensorFlowのチュートリアルでは翻訳モデルででてきます
  - ◆「英語=>フランス語」のデータセットを「発言=>返信」に置換

Recurrent neural networks can learn to model language, as already discussed in the RNN Tutorial (if you did not read it, please go through it before proceeding with this one). This raises an interesting question: <a href="could we condition">could we condition</a> the generated words on some input and generate a meaningful response? For example, could we train a neural network to translate from English to French? It turns out that the answer is yes.

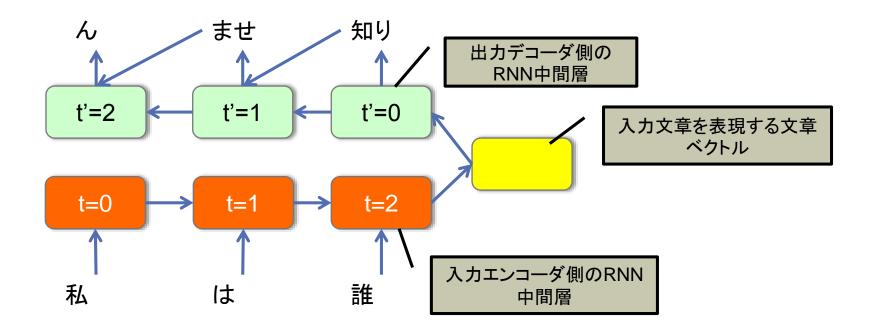
https://www.tensorflow.org/versions/0.6.0/tutorials/seq2seg/index.html

単語群を入力したらそれに対して意味 のある返答ができるのでは?





◆ 入力値をエンコードするRNNとその成化物の中間層をデコードする RNNの二つの組み合わせ



#### その他条件



- ◆ 学習データにはTwitterのツイート、リプライのデータを約40,000セット
- ◆ 句読点、絵文字は除去(記号は残しました)
- ◆ 形態素解析にはMeCabを使用
- ◆ ユーザ辞書などのチューニングは行わず



語彙数は約28000語程度(少ない...)

#### 成長の記録(生後15分)



```
shinmuratakuya-no-MacBook-Pro% python Machina.py tout flush()
I tensorflow/core/common_runtime/local_device.cc:40] Local device intra op parallelism threads: 8
I tensorflow/core/common_runtime/direct_session.cc:58] Direct session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Creating 3 layers of 1024 units.
Reading model parameters from ./data/machina.ckpt-100 session inter op parallelism threads: 8
Crea
```

会話にならないどころか狂気を感じました

## 成長の記録(生後1時間)



生まれて初めて1文字以上の単語を発してくれました

## 成長の記録(生後1日)



```
>こんにちわしししたたたた
> おはようございます
おはよう おはよう ござい ござい ござい ます ωω)
> なんかやっと普通の言葉をはなしてきましたね
え・・! のののののののののののののの
> やっぱり気のせいだったようです。。。。。
おでてててててててててててて
```

挨拶くらいはできるようになったそうです。しかも顔文字らしき ものも覚えているようです。

#### 成長の記録(1日ちょっと)



「こんばんは」は分からないようです





挨拶だけではなく、こちらに質問するようになりました。





```
>こんばんわ
んそれのてててんんた
> こんばんは
      たたたます
> こんにちは
  はようございます
  よう おはよう ござい ござい ます
  ょっとだけかしこくなったね
  それ た が が た た www
  っぱり気のせいかな
            くなってきたわ。資料作るから無視していいですか?
   000
> そんなにショックなの?
 0 0 0 0 0 0 0 0
```

やっと意味が通じる会話になりました!!!



# 実際に使ってみましょう!

### 考察



◆ 一般的な会話の長さに比べてTwitterの文章は長すぎる

```
global step 8500 learning rate 0.4707 step-time 12.18 perplexity 1.69
eval: bucket 0 perplexity 1.73
eval: bucket 1 perplexity 1.31
eval: bucket 2 perplexity 1.52
eval: bucket 3 perplexity 1.57

適合率が一番低い
```

- ◆ 日本語での会話を実現するにはデータ量も少ない
  - ◆ 一般的に成人男性の扱う語彙数は英語だと25,000~30,000語
  - ◆ 一方日本語だと約50,000語と言われている
- ◆ RNNなのでやはり収束速度が遅い
- ◆ 会話生成手法は結局人工無能のまま

#### 今後の方針



- ◆ 単語辞書を生成して形態素解析の精度を上げる
  - ◆ Wikipediaからの形態素解析辞書生成
- ◆ 入力データのクレンジング
  - ◆ 同一botによる応答を除くなど
- ◆ 短文データの対話corpus生成
  - ◆ どっかに落ちてないですかね…?
- ◆ 学習手法の改良
  - ◆ 収束速度を高めるためにAdam法などを採用
- ◆ なんとかして文脈や会話生成の部分も人工知能化したい
  - ◆ 強化学習との相性がいいのではないか?

#### まとめ(感想)



- ◆ TensorFlowのチュートリアルを参考に、会話Alをつくってみました
- ◆ 会話を成立させるのはやはりなかなか難しい
- ◆ TensroFlowで書くと思ってたよりずっとソースコードの量は少なくて済みました(500step程度)
- ◆ 便利なRNN系メソッドを使いすぎて返り値がわからなくなることも....
- ◆ チュートリアルが豊富なおかげで、それを魔改造することによりいろいろ なことができると思います



## ご清聴有難うございました!